

Exercícios: revisão A1

Disciplina: Modelagem Estatística

Instrutor: Luiz Max Carvalho

Monitor: Ezequiel Braga

Abril/2025

Questões

1. **(Weighted regression)** Em muitas situações faz sentido ponderar alguns pontos de dados mais do que outros ao ajustar um modelo de regressão, o que é feito usando mínimos quadrados ponderados. Para isso, considere que estamos interessados em minimizar $\sum_{i=1}^n w_i (y_i - \mathbf{X}_i \boldsymbol{\beta})^2$, para $\mathbf{X} \in \mathbb{R}^{n \times (p+1)}$, com a primeira coluna de 1's; $\mathbf{Y} \in \mathbb{R}^n$; $\boldsymbol{\beta} \in \mathbb{R}^{p+1}$; e $w_i > 0$, $i = 1, \dots, n$.

- (a) Escreva o problema de minimização na forma matricial, usando \mathbf{X} , \mathbf{Y} e $\mathbf{W} = \text{diag}(\mathbf{w})$, com $\mathbf{w} = (w_1, w_2, \dots, w_n)^T$.

Resolução: O problema de minimização que buscamos resolver inicialmente é:

$$\min_{\boldsymbol{\beta}} \sum_{i=1}^n w_i (y_i - \mathbf{X}_i \boldsymbol{\beta})^2.$$

Que pode ser reescrito como:

$$\min_{\boldsymbol{\beta}} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}).$$

- (b) Determine o estimador de mínimos quadrados para $\boldsymbol{\beta}$, $\hat{\boldsymbol{\beta}}_{\text{wls}}$.

Resolução: Neste caso, seguimos o procedimento de otimização. Para $L(\boldsymbol{\beta}) = (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{W} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})$, sabemos que:

$$\hat{\boldsymbol{\beta}}_{\text{wls}} = \arg \min_{\boldsymbol{\beta}} L(\boldsymbol{\beta}).$$

Seguimos:

$$\frac{d}{d\boldsymbol{\beta}} L(\boldsymbol{\beta}) = -2\mathbf{X}^\top \mathbf{W} (\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}).$$

Como L é estritamente convexa (verificar), sabemos que $\frac{d}{d\boldsymbol{\beta}} L(\hat{\boldsymbol{\beta}}_{\text{wls}}) = 0$ e, portanto:

$$\begin{aligned}
-2\mathbf{X}^\top \mathbf{W}(\mathbf{Y} - \mathbf{X}\hat{\boldsymbol{\beta}}_{\text{wls}}) &= 0 \\
\mathbf{X}^\top \mathbf{W}\mathbf{Y} - \mathbf{X}^\top \mathbf{W}\mathbf{X}\hat{\boldsymbol{\beta}}_{\text{wls}} &= 0 \\
\mathbf{X}^\top \mathbf{W}\mathbf{X}\hat{\boldsymbol{\beta}}_{\text{wls}} &= \mathbf{X}^\top \mathbf{W}\mathbf{Y} \\
\hat{\boldsymbol{\beta}}_{\text{wls}} &= (\mathbf{X}^\top \mathbf{W}\mathbf{X})^{-1} \mathbf{X}^\top \mathbf{W}\mathbf{Y}
\end{aligned}$$

- (c) O modelo acima pode ser usado quando a premissa de homocedasticidade é violada, isto é, os erros não possuem a mesma variância. Assim, suponha que $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\epsilon}$, com $\boldsymbol{\epsilon} \sim \text{MVN}(0, \mathbf{V})$ e $\mathbf{V} \in \mathbb{R}^{n \times n}$ tal que $V_{ij} = \begin{cases} \sigma_i^2, & \text{se } i = j; \\ 0, & \text{c.c.} \end{cases}$.
- Calcule a log-verossimilhança do modelo.
 - Determine o estimador de máxima verossimilhança de $\boldsymbol{\beta}$ e deduza a matriz de pesos \mathbf{W} .

Resolução: Temos

$$l(\boldsymbol{\beta}) \propto -\frac{1}{2}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta})^\top \mathbf{V}^{-1}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}).$$

Derivando e usando que, para B simétrica, $\frac{\partial}{\partial s}(x - As)^T B(x - As) = -2A^\top B(x - As)$,

$$\nabla_{\boldsymbol{\beta}} l(\boldsymbol{\beta}) = \mathbf{X}^\top \mathbf{V}^{-1}(\mathbf{Y} - \mathbf{X}\boldsymbol{\beta}).$$

Igualando a 0, concluímos que $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{V}^{-1} \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{V}^{-1} \mathbf{Y}$ e, portanto, $\mathbf{W} = \mathbf{V}^{-1}$.

- O modelo linear (de regressão) é um dos cavalos de batalha da Estatística, sendo aplicado em problemas de Finanças, Medicina e Engenharia. Vamos agora estudar como utilizar as propriedades deste modelo para desenhar experimentos com garantias matemáticas de desempenho e obter estimadores de quantidades de interesse.
 - Uma prática comum em regressão é a de **centrar** a variável independente (covariável), isto é subtrair a média; isto facilita a interpretação do intercepto e também simplifica alguns cálculos importantes. Mostre que no caso com a covariável centrada, $\hat{\beta}_0$ e $\hat{\beta}_1$ são independentes;
 - Mais uma vez considerando o caso centrado, mostre como obter o número de observações n que faz com que a variância do estimador de máxima verossimilhança do intercepto seja menor que $v > 0$;
 - Mostre como obter um estimador não-viesado da quantidade $\theta = a\beta_0 + b\beta_1 + c$, com $a, b, c \neq 0$, e encontre o seu erro quadrático médio.

- d) Quando $x_{\text{pred}} = \bar{x}$, mostre como obter o número de observações n necessário para que o intervalo de predição de $100(1 - \alpha_0)\%$ para a variável-resposta (Y) tenha largura menor ou igual a $l > 0$ com probabilidade pelo menos γ .

Dicas:(i) A expressão dependerá *também* da variância dos resíduos, σ^2 e (ii) Você não precisa calcular n , apenas mostrar o procedimento para obtê-lo.

Resolução: Em uma regressão linear simples, temos:

$$\begin{aligned}\hat{\beta}_0 &\sim \text{Normal} \left(\beta_0, \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{s_x^2} \right) \right), \\ \hat{\beta}_1 &\sim \text{Normal} \left(\beta_1, \frac{\sigma^2}{s_x^2} \right), \\ \text{Cov}(\hat{\beta}_0, \hat{\beta}_1) &= -\frac{\bar{x}\sigma^2}{s_x^2},\end{aligned}$$

onde $s_x = \sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}$ e $\hat{\beta}_0$ e $\hat{\beta}_1$ são os estimadores de máxima verossimilhança dos coeficientes.

Para resolver a) basta perceber que quando substituimos a covariável original X por $X' = X - \bar{x}$ temos $\bar{x}' = 0$ e portanto $\text{Cov}(\hat{\beta}_0, \hat{\beta}_1) = -\frac{\bar{x}'\sigma^2}{s_x^2} = 0$.

Para afirmarmos que $\hat{\beta}_0$ e $\hat{\beta}_1$ são independentes é preciso lembrar que estes estimadores têm distribuição conjunta Normal bivariada; quando a covariância é zero, sabemos que são independentes. A resposta de b) vem mais uma vez utilizando a dica dada. Vemos que no caso centrado a variância de $\hat{\beta}_0$ é σ^2/n . Desta forma, precisamos apenas encontrar n tal que $\sigma^2/n < v$, isto é $n > \sigma^2/v$. Como sabemos que os estimadores dos coeficientes são não-viesados (trabalhado em aula, presente nas dicas), podemos encontrar $\hat{\theta} = a\hat{\beta}_0 + b\hat{\beta}_1 + c$ como nosso estimador não-viesado de θ . O EQM de tal estimador é a sua variância:

$$\begin{aligned}E[(\hat{\theta} - \theta)^2] &= \text{Var}(\hat{\theta}) = a^2 \text{Var}(\hat{\beta}_0) + b^2 \text{Var}(\hat{\beta}_1) - ab \text{Cov}(\hat{\beta}_0, \hat{\beta}_1), \\ &= a^2 \sigma^2 \left(\frac{1}{n} + \frac{\bar{x}^2}{s_x^2} \right) + b^2 \frac{\sigma^2}{s_x^2} + ab \frac{\bar{x}\sigma^2}{s_x^2}, \\ &= \sigma^2 \left(\frac{a^2}{n} + \frac{a^2 \bar{x}^2}{s_x^2} + \frac{b^2}{s_x^2} + \frac{ab\bar{x}}{s_x^2} \right).\end{aligned}$$

Por fim, vamos responder d). Note que a expressão necessária aqui é a do intervalo de predição:

$$\hat{Y} \pm c(n, \alpha_0) \cdot \hat{\sigma}'_r \cdot \sqrt{\left[1 + \frac{1}{n} + \frac{(x_{\text{pred}} - \bar{x})^2}{s_x^2} \right]},$$

onde

$$c(n, \alpha_0) := T^{-1} \left(1 - \frac{\alpha_0}{2}; n - 2 \right),$$

e

$$\hat{\sigma}'_r := \sqrt{\frac{\sum_{i=1}^n (Y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2}{n - 2}}.$$

Quando $x_{\text{pred}} = \bar{x}$ a expressão se reduz um pouco e podemos deduzir que a largura do intervalo é

$$\hat{l} = 2 \cdot c(n, \alpha_0) \cdot \hat{\sigma}'_r \sqrt{\left[1 + \frac{1}{n}\right]}.$$

Desejamos, portanto, encontrar n tal que

$$\Pr(\hat{l} < l) \geq \gamma,$$

$$\Pr\left(\hat{\sigma}'_r < \frac{l}{2 \cdot c(n, \alpha_0) \cdot \sqrt{\left[1 + \frac{1}{n}\right]}}\right) \geq \gamma,$$

isto é conseguimos reduzir nossa afirmação probabilística a uma afirmação com respeito à f.d.a. (ou CDF) de $\hat{\sigma}'_r$. Para completar nossos cálculos só precisamos nos lembrar que $n\hat{\sigma}'_r/\sigma^2$ tem distribuição qui-quadrado com $n - 2$ graus de liberdade (De Groot, Teorema 11.3.2) e, portanto,

$$\Pr(\hat{\sigma}'_r \leq a) = F_\chi\left(\frac{\sigma^2}{n}a; n - 2\right).$$

3. **(Regressão polinomial)** Para $i = 1, 2, \dots, n$, considere o modelo

$$Y_i = aX_i + bX_i^2 + cX_i^3 + d + \varepsilon_i, \quad (1)$$

onde ε_i são variáveis aleatórias com média 0 e variância constante e X_i são constantes observadas.

a) O modelo em questão é linear?

Resolução: Sim, pois é linear nos parâmetros que estão sendo estimados. É um caso especial de regressão linear.

b) Como você estimaria os parâmetros desse modelo? Escreva a função de perda.

Resolução: Podemos estimar por mínimos quadrados, isto é,

$$\hat{\beta} = \arg \min_{\beta} \sum_{i=1}^n [Y_i - (aX_i + bX_i^2 + cX_i^3 + d)]^2,$$

para $\beta = (d, a, b, c)^\top$.

c) É possível obter um estimador não-viesado de $\beta = (d, a, b, c)^\top$?

Resolução: Sim. Reescrevendo o problema para $\mathbf{X} = \begin{bmatrix} 1 & x_1 & x_1^2 & x_1^3 \\ \vdots & \vdots & \vdots & \vdots \\ 1 & x_n & x_n^2 & x_n^3 \end{bmatrix}$

e $\varepsilon = \sigma^2 I_n$, temos $\mathbf{Y} = \mathbf{X}\beta + \varepsilon$, cuja solução dos mínimos quadrados é $\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$. Como vimos na regressão linear, este estimador é não-viesado.

d) Qual a interpretação de d ? E a de b ?

Resolução: d é o intercepto como na regressão linear. Ele representa a mudança esperada em Y_i quando $X_i = 0$. Já b mede a inclinação da curva, isto é, a mudança esperada na inclinação quanto ela muda quando X_i cresce.

e) (Desafio) Mostre que o estimador de mínimos quadrados está bem definido se e somente se todos os X_i são distintos.

Resolução: Precisamos mostrar que $\mathbf{X}^\top \mathbf{X}$ é invertível. A ideia é usar que $\text{rank}(\mathbf{X}^\top \mathbf{X}) = \text{rank}(\mathbf{X})$. Assim, precisamos mostrar que $\text{rank}(\mathbf{X}) = p + 1$ (nesse caso, $p = 3$). Antes de tudo, precisamos ter $n \geq p + 1$ para ser possível satisfazer o rank desejado. Considere \mathbf{Z} o bloco de \mathbf{X} formado pelas primeiras $p + 1$ linhas, isto é,

$$\mathbf{Z} = \begin{bmatrix} 1 & x_1 & x_1^2 & x_1^3 \\ 1 & x_2 & x_2^2 & x_2^3 \\ 1 & x_3 & x_3^2 & x_3^3 \\ 1 & x_4 & x_4^2 & x_4^3 \end{bmatrix}.$$

Note que \mathbf{Z} é uma matriz de Vandermonde, cujo determinante é conhecido por ser

$$\det(\mathbf{Z}) = \prod_{0 \leq i < j \leq p+1} (x_j - x_i).$$

Logo, $\det(\mathbf{Z}) \neq 0 \Leftrightarrow x_i \neq x_j, \forall i, j = 1, \dots, p+1$, ou seja, $\text{rank}(\mathbf{X}) = \text{rank}(\mathbf{Z}) = p+1 \Leftrightarrow x_i \neq x_j, \forall i, j = 1, \dots, p+1$, o que conclui a prova.

4. **(Família exponencial)** Considere as distribuições de probabilidade abaixo. Usando as propriedades da família exponencial, para cada uma, mostre:

- i) A estatística suficiente e sua esperança
- ii) O estimador de máxima verossimilhança.

(a) **Pareto.** Para $y > 1$ e $\theta > 0$ a densidade vale

$$f(y; \theta) = \theta y^{-\theta-1}.$$

(b) **Binomial negativa.** Para $y \in \mathbb{N} \cup \{0\}$ e $\theta, \phi > 0$ a função de massa vale

$$f(y; \theta) = \binom{y + \phi - 1}{y} \left(\frac{\theta}{\theta + \phi} \right)^y \left(\frac{\phi}{\theta + \phi} \right)^\phi,$$

com ϕ fixo e conhecido.

Resolução: Tome uma família exponencial em forma canônica, isto é, $f_{\mathbf{X}}(x | \boldsymbol{\eta}) = h(x) \exp\{\boldsymbol{\eta}^\top T(x) - A(\boldsymbol{\eta})\}$, onde fica evidente que, para uma amostra aleatória X_1, X_2, \dots, X_n , $T(\mathbf{X}) = \sum_{i=1}^n T(X_i)$ é estatística suficiente, pelo teorema da fatorização. Fica de exercício verificar que $\nabla A(\boldsymbol{\eta}) = \mathbb{E}_{\boldsymbol{\eta}}[T(\mathbf{X})] =: \boldsymbol{\mu}(\boldsymbol{\eta})$ e que $\hat{\boldsymbol{\eta}}_{\text{MLE}} = \boldsymbol{\mu}^{-1} \left(\frac{1}{n} \sum_{i=1}^n T(X_i) \right)$. A partir

disso, basta escrever as distribuições acima na forma canônica e obter as respostas. Para a Pareto($\theta, 1$), $A(\eta) = -\log(-1 - \eta)$ e $T(x) = \log(x)$, o que nos leva a $\mu(\eta) = -\frac{1}{1+\eta}$ e $\hat{\eta}_{\text{MLE}} = -\frac{n}{\sum_{i=1}^n \log(X_i)} - 1$. Logo, $\mathbb{E}[T(\mathbf{X})] = -\frac{n}{1+\eta} = \frac{n}{\theta}$. Agora, note que $\eta = -\theta - 1$, ou seja, $\hat{\theta}_{\text{MLE}} = -\hat{\eta}_{\text{MLE}} - 1 = \frac{n}{\sum_{i=1}^n \log(X_i)}$ (pela invariância do MLE). Para a binomial negativa, temos $A(\eta) = -\phi \log(1 - \exp(\eta))$, $T(x) = x$ e $\eta = \log\left(\frac{\theta}{\theta + \phi}\right)$, o que nos leva a $\mu(\eta) = \frac{\phi \exp(\eta)}{1 - \exp(\eta)}$ e $\hat{\eta}_{\text{MLE}} = \log\left(\frac{\bar{X}}{\bar{X} + \phi}\right)$. Como $\eta = \log\left(\frac{\theta}{\theta + \phi}\right)$, $\hat{\eta}_{\text{MLE}} = \bar{X}$. Além disso, $\mathbb{E}[T(\mathbf{X})] = \frac{n\phi \exp(\eta)}{1 - \exp(\eta)} = n\theta$.