

Exercícios: revisão A2

Disciplina: Modelagem Estatística

Instrutor: Luiz Max Carvalho

Monitor: Ezequiel Braga

Junho/2025

Questões

1. **(GLM com Weibull)** Seja $\mathbf{Y} = \{Y_1, \dots, Y_n\}$ observações do tempo de falha de um certo equipamento associadas à matriz de covariáveis $\mathbf{X} \in \mathbb{R}^{n \times p}$. Considere o seguinte modelo:

$$Y_i | X_i \sim \text{Weibull}(\alpha, \theta_i), \\ \mathbb{E}[Y_i^\alpha | X_i] = g^{-1}(X_i \boldsymbol{\beta}),$$

com α conhecido.

Dica: Se $Y \sim \text{Weibull}(\alpha, \theta)$, então sua p.d.f. é dada por

$$f_Y(y; \alpha, \theta) = \frac{\alpha y^{\alpha-1}}{\theta^\alpha} \exp\left[-\left(\frac{y}{\theta}\right)^\alpha\right].$$

Além disso $E[Y^r] = \theta^r \Gamma(1 + r/\alpha)$.

- Para α conhecido, mostre que a distribuição de Weibull pertence à família exponencial.
- Mostre como escolher g e calcule a log-verossimilhança do modelo.
- Para calcular $\hat{\boldsymbol{\beta}}$, precisamos resolver a equação $\nabla l(\boldsymbol{\beta}) = 0$. Porém, muitas vezes não existe solução analítica e precisamos usar algum método numérico. Neste caso, podemos utilizar Newton Raphson, que consiste em fazer atualizações da forma

$$\boldsymbol{\beta}^{(m+1)} = \boldsymbol{\beta}^{(m)} - \mathcal{H}^{-1}(\boldsymbol{\beta}^{(m)}) \nabla l(\boldsymbol{\beta}^{(m)}),$$

para algum chute inicial $\boldsymbol{\beta}^{(0)}$ – \mathcal{H} denota a matriz hessiana. Calcule $\nabla l(\boldsymbol{\beta}^{(m)})$ e $\mathcal{H}(\boldsymbol{\beta}^{(m)})$.

2. **(LMM):** Seja $\mathbf{Y}_i = (Y_{i1}, \dots, Y_{id})^\top$ vetores independentes correspondentes a observações para cada grupo $i = 1, \dots, n$. Considere matrizes de covariáveis \mathbf{X}_i e \mathbf{Z}_i . Assuma que

$$\mathbf{Y}_i = \mathbf{X}_i\boldsymbol{\beta} + \mathbf{Z}_i\mathbf{U}_i + \boldsymbol{\varepsilon}_i,$$

onde $\boldsymbol{\beta}$ é um vetor p de efeitos fixos, $\mathbf{U}_i \sim \text{Normal}(0, \boldsymbol{\Sigma})$ é um vetor $q \times 1$ de efeitos aleatórios, e $\boldsymbol{\varepsilon}_i = (\varepsilon_{i1}, \dots, \varepsilon_{id})^\top \sim \text{Normal}(0, \mathbf{R})$.

(a) Podemos escrever $\mathbf{Y} = \mathbf{X}\boldsymbol{\beta} + \mathbf{Z}\mathbf{U} + \boldsymbol{\varepsilon}$. Escreva explicitamente \mathbf{X} e \mathbf{Z} .

(b) É possível mostrar que $\mathbf{Y} \sim \text{Normal}(\boldsymbol{\mu}, \mathbf{V})$. Determine $\boldsymbol{\mu}$ e \mathbf{V} .

(c) Determine o estimador de máxima verossimilhança, $\hat{\boldsymbol{\beta}}_{\text{EMV}}$.

Dica: Para \mathbf{W} simétrica, $\frac{d}{ds}(\mathbf{x} - \mathbf{As})^\top \mathbf{W}(\mathbf{x} - \mathbf{As}) = -2\mathbf{A}^\top \mathbf{W}(\mathbf{x} - \mathbf{As})$.

(d) Encontre a distribuição conjunta de $(\mathbf{Y}, \mathbf{U})^\top$.

(e) Mostre que $\mathbb{E}[\mathbf{U} | \mathbf{Y} = \mathbf{y}] = \boldsymbol{\Sigma} \mathbf{Z}^\top \mathbf{V}^{-1}(\mathbf{y} - \mathbf{X}\boldsymbol{\beta})$.

Dica: Use que se $\begin{bmatrix} \mathbf{X}_1 \\ \mathbf{X}_2 \end{bmatrix} \sim \text{Normal} \left(\begin{bmatrix} \boldsymbol{\mu}_1 \\ \boldsymbol{\mu}_2 \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{12}^\top & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right)$, então,

$$\mathbf{X}_1 | \mathbf{X}_2 = \mathbf{x}_2 \sim \text{Normal}(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}_2 - \boldsymbol{\mu}_2), \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}).$$

3. **(Modelo Poisson Multinível)** Considere Y_{ij} contagens para $i = 1, 2, \dots, n$ no grupo $j = 1, 2, \dots, m$. Suponha que observamos uma covariável x_{ij} e postulamos que as observações são Poisson condicionalmente independentes com média

$$\mathbb{E}[Y_{ij} | u_j, x_{ij}] = \exp(u_j + \beta_0 + \beta_1 x_{ij}),$$

onde u_j é um efeito aleatório por grupo.

(a) Uma propriedade fundamental em um modelo multinível é que os efeitos aleatórios introduzem dependência nas observações. Vamos mostrar isso quando $u_j \sim \text{Normal}(0, \tau^2)$.

- i. Temos que $\mathbb{E}[Y_{ij}] = \mathbb{E}[\exp(u_j)] \exp(\beta_0 + \beta_1 x_{ij})$. Determine $\mathbb{E}[\exp(u_j)]$.
- ii. Determine a variância marginal de Y_{ij} .

- iii. Determine $\text{Cov}(Y_{kj}, Y_{lj})$ para $k \neq l$.

(b) Para estimar $\boldsymbol{\beta} = (\beta_0, \beta_1)^\top$ por máxima verossimilhança precisamos marginalizar $\mathbf{u} = (u_1, \dots, u_m)^\top$. Exiba a verossimilhança marginal conjunta $f_{\mathbf{Y}}(\mathbf{y} | \mathbf{X}, \boldsymbol{\beta}, \tau^2)$, onde $\mathbf{Y} = (Y_{11}, Y_{12}, \dots, Y_{nm})^\top$ e \mathbf{X} é a matriz de desenho.

4. **(Estimação do ATE)** Suponha que realizamos um ensaio clínico aleatorizado (*randomized controlled trial*, RCT) com n participantes, onde atribuímos um tratamento binário $W_i \in \{0, 1\}$ e medimos uma variável resposta Y_i para cada participante $i = 1, \dots, n$. Para cada $w \in \{0, 1\}$, definimos respostas potenciais $Y_i(w)$ tal que $Y_i = Y_i(W_i)$. Uma quantidade

de interesse, então, é o efeito do tratamento nos indivíduos, $\Delta_i = Y_i(1) - Y_i(0)$. No entanto, um problema fundamental na inferência causal é que só podemos atribuir um tratamento a cada indivíduo, isto é, só observamos $Y_i(1)$ ou $Y_i(0)$. Em amostras finitas, sem hipóteses sobre como os participantes foram gerados, é possível obter estimadores não-viesados e consistentes do efeito médio amostral do tratamento, $\bar{\Delta} := \frac{1}{n} \sum_{i=1}^n Y_i(1) - Y_i(0)$. Se assumirmos que os participantes são selecionados de uma população P , também é possível obter estimadores não-viesados e consistentes do efeito médio do tratamento na população, $\tau = \mathbb{E}_P[Y_i(1) - Y_i(0)]$. Vamos definir e verificar algumas propriedades desses métodos de estimação.

- (a) A maneira mais intuitiva de proceder é através do estimador de diferença de médias,

$$\hat{\tau}_{\text{DM}} = \frac{1}{n_1} \sum_{i=1}^n Y_i(1)W_i - \frac{1}{n_0} \sum_{i=1}^n Y_i(0)(1 - W_i),$$

onde $n_w = \sum_{i=1}^n \mathbf{1}\{W_i = w\}$. Suponha que o tratamento é aleatoriamente de fato, ou seja,

$$\Pr(W_i = 1 | \{Y_i(1), Y_i(0)\}_{i=1}^n, n_1) = \frac{n_1}{n}.$$

Mostre que $\hat{\tau}_{\text{DM}}$ é um estimador não-viesado de $\bar{\Delta}$, dado $\{Y_i(1), Y_i(0)\}_{i=1}^n$.

- (b) Uma limitação do resultado anterior é que não caracteriza o erro padrão de $\hat{\tau}_{\text{DM}} - \bar{\Delta}$. Sendo assim, suponha que produzimos um ensaio Bernoulli, com

$$W_i | \{Y_i(0), Y_i(1)\} \sim \text{Bernoulli}(p), \quad 0 < p < 1.$$

Supondo que $\{Y_i(0), Y_i(1)\} \sim P$, mostre que

$$\sqrt{n}(\hat{\tau}_{\text{DM}} - \tau) \xrightarrow{d} \text{Normal}(0, V_{\text{DM}}),$$

$$\text{onde } V_{\text{DM}} = \frac{\text{Var}(Y_i(1))}{p} + \frac{\text{Var}(Y_i(0))}{1-p}.$$

- (c) Uma outra maneira de estimar o ATE é via regressão linear. Para isso, suponha que

$$Y_i = \alpha + W_i\tau + \varepsilon_i,$$

com $\varepsilon_i \sim \text{Normal}(0, \sigma^2)$. Assim, podemos obter um estimador de τ por máxima verossimilhança ou mínimos quadrados, $\hat{\tau}_{\text{MLE}}$.

- i. Mostre que $\hat{\tau}_{\text{MLE}} = \hat{\tau}_{\text{DM}}$.
- ii. Usando as propriedades do estimador de máxima verossimilhança, mostre como construir um intervalo de confiança γ para τ .