Lista de revisão A2

1. Come Together.

Sejam $Y_1, \ldots, Y_n$ observações independentes, cada uma com densidade (ou função de probabilidade) na família exponencial de dispersão,

$$f(y_i; \theta_i, \phi) = \exp\left\{ \frac{y_i \theta_i - b(\theta_i)}{a(\phi)} + c(y_i, \phi) \right\},$$

e suponha que adotamos a **ligação canônica**, de modo que o parâmetro canônico coincide com o preditor linear: $\theta_i = \eta_i = x_i^\top \beta$. Denote $\mu_i = E[Y_i] = b'(\theta_i)$, e seja X a matriz de desenho $n \times p$ cujas linhas são os $x_i^\top$.

a) Mostre que a função score pode ser escrita na forma

$$U(\beta) = \frac{1}{a(\phi)} X^\top (y - \mu), \qquad \mu = (\mu_1, \ldots, \mu_n)^\top.$$

b) Mostre que, sob a ligação canônica, a informação observada coincide com a informação esperada (de Fisher). Conclua que o algoritmo de Newton–Raphson e o *Fisher scoring* produzem exatamente as mesmas iterações.

c) As equações de (máxima) verossimilhança são $X^\top (y - \hat{\mu}) = 0$. O que podemos dizer sobre os resíduos brutos $y_i - \hat{\mu}_i$ e sobre a(s) estatística(s) suficiente(s)? Quando o modelo inclui o intercepto, o que se pode afirmar sobre $\sum_i (y_i - \hat{\mu}_i)$?

2. Should I Stay or Should I Go.

Um serviço de *streaming* quer entender o cancelamento (*churn*) de assinantes. Para cada cliente i, seja $Y_i = 1$ se ele cancelou no período de observação e 0 caso contrário, com $Y_i \sim$ Bernoulli(p_i) e

$$\text{logit}(p_i) = \beta_0 + \beta_1 \, \texttt{meses}_i + \beta_2 \, \texttt{premium}_i,$$

onde `meses` é o tempo de assinatura e `premium` $= 1$ para o plano premium. O ajuste produziu:

```
Call:
glm(formula = churn ~ meses + premium, family = "binomial", data = streaming)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -2.00417    0.21356  -9.385  < 2e-16 ***
meses       -0.04982    0.01187  -4.197 2.7e-05 ***
premium     -0.80213    0.24509  -3.273  0.00106 **

    Null deviance: 458.92  on 499  degrees of freedom
Residual deviance: 412.74  on 497  degrees of freedom
```

Ao reajustar o modelo **sem** a covariável `premium`, obtém-se *deviance* residual de 423.93 sobre 498 graus de liberdade.

a) Interprete os coeficientes de `meses` e de `premium` na escala de razão de chances (*odds ratio*).

b) Calcule a probabilidade estimada de cancelamento de um cliente premium com 12 meses de assinatura.

c) Use as *deviances* para testar formalmente se `premium` contribui para o modelo. Enuncie as hipóteses, a estatística de teste, sua distribuição de referência e a conclusão.

d) Um colega sugere usar a *deviance* residual (412.74 sobre 497 g.l.) comparada a uma χ^2_{497} para avaliar a qualidade do ajuste. Por que essa estratégia **não** é válida aqui?

3. Highway to Hell.

Um engenheiro de tráfego modela o número de acidentes Y_i em n cruzamentos ao longo de um ano. Cada cruzamento tem uma **exposição**[1] $\texttt{volume}_i$ (em veículos·hora), e ele propõe $Y_i \sim \text{Poisson}(\mu_i)$ com

$$\log(\mu_i) = \log(\texttt{volume}_i) + \beta_0 + \beta_1\,\texttt{iluminada}_i + \beta_2\,\texttt{limite}_i,$$

onde $\texttt{iluminada} = 1$ se o cruzamento tem iluminação noturna e `limite` é o limite de velocidade (em dezenas de km/h). O ajuste:

```
Call:
glm(formula = acidentes ~ iluminada + limite + offset(log(volume)),
    family = "poisson", data = cruzamentos)

Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -8.51234    0.18642 -45.663  < 2e-16 ***
iluminada   -0.35667    0.07953  -4.485 7.3e-06 ***
limite       0.12384    0.03017   4.105 4.0e-05 ***

    Null deviance: 251.07  on 148  degrees of freedom
Residual deviance: 220.46  on 146  degrees of freedom
```

A estatística de Pearson do modelo ajustado é $\chi^2 = 210.4$.

a) (10 pontos) Explique o papel do termo $\log(\texttt{volume}_i)$. Por que ele entra **sem coeficiente a estimar**, e como isso transforma um modelo de contagens em um modelo de taxas?

b) (10 pontos) Interprete o coeficiente de `iluminada` na escala apropriada.

c) (15 pontos) Investigue a presença de sobredispersão. Estime o parâmetro de dispersão, decida se há sobredispersão e discuta as consequências para a inferência e os possíveis remédios.

4. Under Pressure.

A sobredispersão de contagens costuma surgir de heterogeneidade não observada. Um modelo clássico para isso é a mistura **Poisson–Gama**: condicionalmente a uma taxa latente λ,

$$Y \mid \lambda \sim \text{Poisson}(\lambda), \qquad \lambda \sim \text{Gama}, \quad \text{com } E[\lambda] = \mu \;\text{ e }\; \text{Var}(\lambda) = \mu^2/r,$$

onde $r > 0$ é **conhecido**.

a) (10 pontos) Usando as leis da esperança e da variância totais, mostre que $E[Y] = \mu$ e $\text{Var}(Y) = \mu + \mu^2/r$.

b) (10 pontos) Mostre que há sobredispersão em relação à Poisson e descreva o comportamento do modelo quando $r \to \infty$.

c) (15 pontos) A marginal de Y é a Binomial Negativa,

$$\Pr(Y = y) = \frac{\Gamma(y + r)}{\Gamma(r)\,y!}\left(\frac{r}{r+\mu}\right)^r\left(\frac{\mu}{r+\mu}\right)^y, \quad y = 0, 1, 2, \ldots$$

[1] Também chamado de *offset*.

Mostre que, para r fixo, ela pertence à família exponencial; identifique o parâmetro canônico θ e mostre que a função de variância é $V(\mu) = \mu + \mu^2/r$. Comente por que a hipótese de r conhecido é essencial.