

Trabalho II: Dados faltantes e estimação por máxima verossimilhança

- A tarefa deve ser entregue, em formato **impresso**, até o dia 24/06 às 16h de Brasília **impreterivelmente**;
- A tarefa vale 100 pontos – com peso 1/2 na nota da A2. A pontuação restante é contada como bônus;
- **Política de colaboração:** o trabalho é individual. Você deve reportar o conteúdo de quaisquer comunicações com colegas ou outros indivíduos.
- **Política de utilização de inteligência artificial (IA):** O uso de IA é permitido, desde que você reporte o modelo com o qual interagiu e documente meticulosamente os *prompts* utilizados e a motivação por trás deles. Lembre-se: a IA já tem emprego!

Motivação

Dados faltantes são onipresentes em aplicações estatísticas reais. A resposta mais simples (descartar as observações incompletas e trabalhar apenas com os casos completos) desperdiça informação e pode introduzir viés. Uma resposta mais elegante, devida a T.W. Anderson (1957), mostra que a estrutura da distribuição normal multivariada pode ser explorada para obter estimadores de máxima verossimilhança (máxima verossimilhança) de forma surpreendentemente simples, sem qualquer algoritmo iterativo.

A ideia central é a **fatoração da verossimilhança**: em vez de maximizar a log-verossimilhança conjunta de todos os parâmetros simultaneamente, podemos reescrevê-la como soma de duas partes que envolvem conjuntos *distintos* de parâmetros, permitindo maximização independente de cada parte.

Neste estudo dirigido vamos redescobrir essa ideia usando dados reais de qualidade do ar. O conjunto de dados `airquality`, disponível no R `base`, contém $n = 153$ medições diárias em Nova York (maio–setembro de 1973). As duas variáveis de interesse são:

- $Y_1 = \text{Solar.R}$: radiação solar (em Langleys, 08h–12h, Aeroporto JFK);
- $Y_2 = \text{Ozone}$: concentração média de ozônio (partes por bilhão (ppb), 13h–15h, Roosevelt Island).

Questão 1: análise exploratória (20 pontos)

Selecione as variáveis `Solar.R` e `Ozone` do dataset e classifique cada observação em um dos três padrões de dados faltantes: *completo* (ambas observadas), *parcial* (Y_1 observada, Y_2 faltante) e *invertido* (Y_2 observada, Y_1 faltante). Quantas observações há em cada padrão? O padrão é aproximadamente **monotônico**? Dizemos que um padrão é monotônico quando, para todo par de variáveis, qualquer observação com Y_2 faltante também tem Y_1 faltante – ou vice-versa.

Faça um gráfico de dispersão de Y_2 versus Y_1 para os casos completos e avalie visualmente a linearidade da relação. Experimente também o gráfico de $\log(Y_2)$ versus Y_1 . Qual transformação parece mais adequada para satisfazer a suposição de normalidade bivariada? Justifique com histogramas e/ou diagramas de nível bivariados.

Calcule a média amostral de Y_1 usando: (i) apenas os casos com Y_1 e Y_2 observados; (ii) todos os casos em que Y_1 está observada. As duas estimativas diferem? Qual tem menor erro padrão e por quê?

Por fim, suponha que a probabilidade de Y_2 estar faltante depende apenas do valor observado de Y_1 (mecanismo *Missing at Random*, MAR). O que isso significa neste problema? Você acha plausível essa suposição para dados de ozônio e radiação solar? Por quê?

Questão 2: O estimador de casos completos (40 pontos)

Seja r o número de casos completos (com Y_1 e Y_2 ambos observados) e n o total de observações com Y_1 observada. Usando apenas os r casos completos, estime os cinco parâmetros da distribuição normal bivariada: $\hat{\mu}_1^{CC}, \hat{\mu}_2^{CC}, \hat{\sigma}_{11}^{CC}, \hat{\sigma}_{22}^{CC}, \hat{\sigma}_{12}^{CC}$. Use as fórmulas amostrais de máxima verossimilhança (divisão por r).

Mostre *numericamente* que o estimador de μ_1 usando todos os n casos tem erro padrão menor do que aquele baseado apenas nos r casos completos. Qual é a razão $\sqrt{r/n}$ nos seus dados?

Sob MAR, o estimador CC para μ_2 é não viesado? Apresente um argumento intuitivo e verifique empiricamente via simulação: gere 1.000 amostras de uma normal bivariada com os parâmetros estimados, aplique o mecanismo MAR artificialmente e compare as médias dos estimadores CC e do verdadeiro μ_2 .

Construa um intervalo de confiança de 95% para μ_2 usando o estimador CC.

Questão 3: fatoração da verossimilhança (40 pontos)

Suponha que $(Y_{i1}, Y_{i2}) \stackrel{\text{iid}}{\sim} \text{normal}_2(\mu, \Sigma)$, com Y_{i2} faltante para $i = r + 1, \dots, n$ e MAR. A log-verossimilhança dos dados observados é:

$$\begin{aligned} \ell(\mu, \Sigma \mid Y_{\text{obs}}) = & -\frac{r}{2} \ln |\Sigma| - \frac{1}{2} \sum_{i=1}^r (y_i - \mu)^T \Sigma^{-1} (y_i - \mu) \\ & - \frac{n-r}{2} \ln \sigma_{11} - \frac{1}{2\sigma_{11}} \sum_{i=r+1}^n (y_{i1} - \mu_1)^2. \end{aligned} \quad (1)$$

Mostre que a distribuição conjunta de (Y_{i1}, Y_{i2}) pode ser fatorada como:

$$f(y_{i1}, y_{i2} \mid \mu, \Sigma) = f_1(y_{i1} \mid \mu_1, \sigma_{11}) \cdot f_2(y_{i2} \mid y_{i1}, \beta_{20.1}, \beta_{21.1}, \sigma_{22.1}),$$

e exiba as expressões para os parâmetros da regressão condicional, $\beta_{20.1}, \beta_{21.1}, \sigma_{22.1}$.

Usando essa fatoração, mostre que a log-verossimilhança (1) pode ser reescrita como:

$$\ell(\phi \mid Y_{\text{obs}}) = \ell_1(\mu_1, \sigma_{11}) + \ell_2(\beta_{20.1}, \beta_{21.1}, \sigma_{22.1}),$$

onde $\phi = (\mu_1, \sigma_{11}, \beta_{20.1}, \beta_{21.1}, \sigma_{22.1})^T$ é uma função bijetora de $\theta = (\mu_1, \mu_2, \sigma_{11}, \sigma_{12}, \sigma_{22})^T$, e ℓ_1 usa todos os n valores de Y_1 enquanto ℓ_2 usa apenas os r casos completos.

Argumente que podemos maximizar ℓ_1 e ℓ_2 *independentemente* e derive os estimadores de máxima verossimilhança de ϕ . Mostre que o estimador de máxima verossimilhança de μ_2 é:

$$\hat{\mu}_2^{MV} = \bar{y}_2 + \hat{\beta}_{21.1} (\hat{\mu}_1 - \bar{x}_1), \quad (2)$$

onde $\bar{y}_2$ e $\bar{x}_1$ são as médias amostrais dos r casos completos, $\hat{\mu}_1 = n^{-1} \sum_{i=1}^n y_{i1}$ usa todos os n casos, e $\hat{\beta}_{21.1} = s_{12}/s_{11}$ é estimado nos r casos completos. Implemente o estimador (2) no R e compare com $\hat{\mu}_2^{CC}$. O que muda e por quê?

Extra: Quantificação da Incerteza (40 pontos)

O estimador de Anderson é uma função não linear de estatísticas de dois subconjuntos de dados. Implemente o seguinte procedimento de bootstrap paramétrico para quantificar sua incerteza:

1. Estime os parâmetros $\hat{\mu}$ e $\hat{\Sigma}$ pelo estimador de Anderson.
2. Simule $B = 2.000$ amostras de tamanho n de $\text{normal}_2(\hat{\mu}, \hat{\Sigma})$.
3. Em cada amostra, aplique o mesmo padrão de dados faltantes observado nos dados reais.
4. Aplique o estimador de Anderson a cada amostra e guarde $\hat{\mu}_2^{(b)}$.
5. Reporte o desvio padrão de $\{\hat{\mu}_2^{(b)}\}$ como estimativa do erro padrão.

Compare os intervalos de confiança de 95% para μ_2 obtidos por: (i) estimador CC (Questão 2); (ii) estimador de Anderson com bootstrap paramétrico; (iii) estimador de Anderson com bootstrap não paramétrico (reamostrar linhas com reposição). Qual intervalo é mais estreito? Isso era esperado?

A eficiência relativa do estimador de Anderson frente ao CC depende de quais quantidades do modelo? Em que regime – correlação alta ou baixa entre Y_1 e Y_2 ; fração de dados faltantes alta ou baixa – o ganho é maior? Elabore sua resposta com uma pequena simulação.

Referências

- Anderson, T.W. (1957). Maximum Likelihood Estimates for a Multivariate Normal Distribution When Some Observations Are Missing. *Journal of the American Statistical Association*, 52, 200–203.
- Little, R. J. (1994). A Class of Pattern-Mixture Models for Normal Missing Data. *Biometrika*, 81(3), 471–483.
- Little, R. J. (2013). In Praise of Simplicity not Mathematistry! Ten Simple Powerful Ideas for the Statistical Scientist. *Journal of the American Statistical Association*, 108(502), 359–369.
- Little, R. J. & Rubin, D. B. (2002). *Statistical Analysis with Missing Data*, 2^a ed. Wiley.
- Rubin, D. B. (1976). Inference and Missing Data. *Biometrika*, 63(3), 581–592.