

Primeira avaliação (A1)

Disciplina: Modelagem Estatística
Instrutor: Luiz Max Carvalho
Monitores: Ezequiel Braga & Yure Santos

17 de Abril de 2026

- O tempo para realização da prova é de 3 horas;
- Leia a prova toda com calma antes de começar a responder;
- Responda todas as questões sucintamente;
- Marque a resposta final claramente com um quadrado, círculo ou figura geométrica de sua preferência;
- A prova vale 90 pontos. A pontuação restante é contada como bônus;
- Você tem direito a trazer uma folha de “cola” tamanho A4 frente e verso, que deverá ser entregue junto com as respostas da prova.

Notação: Como convenção adotamos $\mathbb{R} = (-\infty, \infty)$, $\mathbb{R}_+ = (0, \infty)$ e $\mathbb{N} = \{1, 2, \dots\}$.

1. Comparison is the thief of joy.

Como visto em aula, é sempre importante comparar os modelos em termos do seu ajuste aos dados. Um dos indicadores de bondade do ajuste mais utilizados na prática é o chamado coeficiente de determinação (R^2) que se propõe a medir a quantidade de variância “explicada”. Neste exercício vamos estudar algumas propriedades e características do R^2 .

- (10 pontos) Defina o R^2 matematicamente, e mostre como interpretá-lo. Além das premissas usuais do modelo linear, que condições precisam ser satisfeitas pelo modelo que está sendo comparado? Qual a base de comparação?
- (10 pontos) Mostre que o R^2 não diminui ao se incluírem mais preditores. Interprete esse resultado. **Dica:** Use que

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{bmatrix},$$

para A e D quadradas e B e C com as respectivas dimensões compatíveis.

- (10 pontos) Para um modelo com P covariáveis, defina a hipótese nula (H_0) usual e calcule a distribuição amostral do R^2 sob H_0 . **Dica:** Mostre que se $U \sim \chi^2(a)$ e $V \sim \chi^2(b)$, com $U \perp V$, então $U/(U + V) \sim \text{Beta}(a/2, b/2)$.

Conceitos trabalhados: distribuição amostral de estimadores; modelo linear; soma de quadrados; bondade do ajuste. **Nível de dificuldade:** fácil.

Resolução: Considere o modelo linear $y = \alpha 1 + X\gamma + \varepsilon$, com $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$ e defina $\tilde{X} = [1, X]$ e $\beta = [\alpha, \gamma]^\top$. Seja $S = (y - \bar{y}1)^\top (y - \bar{y}1)$ e $S_0 = (y - \hat{y})^\top (y - \hat{y})$. Definimos o R^2 como

$$R^2 = 1 - \frac{S_0}{S}.$$

Ele é uma medida de bondade do ajuste que compara o modelo ajustado com o modelo mais simples possível, ou seja, o modelo que atribui a mesma média para todo indivíduo, $y_i = \alpha, \forall i = 1, \dots, n$, cujo estimador é $\hat{\alpha} = \bar{y}$. Pode ser interpretado como a proporção da variação total nos dados que é explicada pelo modelo: se o modelo ajustado não é tão melhor que o modelo mínimo, $S_0 \approx S$ e então $R^2 \approx 0$; analogamente, se o modelo ajustado é muito melhor que o modelo mínimo, $S_0 \ll S$ e, portanto, $R^2 \approx 1$. Para responder o segundo item, note que o erro quadrático sempre diminui ao se incluir mais uma covariável, pois tomando $\beta_{P+1} = 0$ recuperamos o erro do modelo com P covariáveis e ao minimizar o erro do modelo com $P + 1$ covariáveis o erro será sempre menor ou igual do que fixando $\beta_{P+1} = 0$. Alternativamente, pode-se usar a dica para encontrar o estimador no modelo com $P + 1$ covariáveis e mostrar explicitamente

que S_0 é menor ou igual no modelo maior. Para o último item, perceba que $S = S_0 + S_1$. Logo,

$$R^2 = \frac{S_1}{S_1 + S_0}.$$

Vamos mostrar que $\frac{1}{\sigma^2} S_1 \sim \chi^2(P)$ sob H_0 . Note que $S_1 = y^\top (H - J)y = (1\beta_0 + \varepsilon)^\top (H - J)(1\beta_0 + \varepsilon) = \varepsilon^\top (H - J)\varepsilon$, onde J é uma matriz quadrada com $1/n$ em todas as entradas. Logo,

$$\frac{S_1}{\sigma^2} = Z^\top (H - J)Z,$$

onde $Z \sim N(0, I_n)$. Como $H - J$ é simétrica, idempotente e $\text{tr}(H - J) = P$, então $H - J$ tem P autovalores iguais a 1 e $n + 1 - P$ autovalores nulos. Logo, pelo Teorema Espectral, $H - J = Q^\top \Lambda Q$, onde Λ é diagonal com os autovalores de $H - J$. Portanto

$$Z^\top (H - J)Z = (QZ)^\top \Lambda (QZ) = \sum_{i=2}^{P+1} (QZ)_i^2.$$

Como Q é ortogonal, então $QZ \sim N(0, I_n)$ e concluímos que $S_1/\sigma^2 \sim \chi^2(P)$. Para S_0 , observe que

$$S_0 = y^\top (I - H)y = (\tilde{X}\beta + \varepsilon)^\top (I - H)(\tilde{X}\beta + \varepsilon) = \varepsilon^\top (I - H)\varepsilon.$$

Como $I - H$ projeta em um subespaço de dimensão $n - P - 1$, um raciocínio semelhante mostra que

$$\frac{S_0}{\sigma^2} = (QZ)^\top (I - \Lambda - \Lambda_J)(QZ) = \sum_{i=P+2}^n (QZ)_i^2,$$

onde Λ_J é uma matriz com 1 na entrada $(1, 1)$ e 0 nas restantes. Logo $S_0/\sigma^2 \sim \chi^2(n - P - 1)$ e $S_0 \perp S_1$, pois eles somam entradas diferentes do vetor QZ de gaussianas independentes. Agora resta mostrar a dica. Para isso, vamos usar transformação de variáveis. Seja $Z = U + V$ e $W = \frac{U}{Z}$. Logo, $Z \sim \chi^2(n - 1)$ e

$$f_{W,Z}(w, z) = |J(w, z)|^{-1} f_{U,V}(wz, z(1 - w)),$$

onde

$$\begin{aligned} |J(w, z)| &= \left| \begin{bmatrix} \frac{v}{(u+v)^2} & -\frac{u}{(u+v)^2} \\ 1 & 1 \end{bmatrix} \right|, \\ &= \frac{v + u}{z^2}, \\ &= \frac{1}{z}. \end{aligned}$$

Assim,

$$f_{W,Z}(w, z) = \frac{z^{a/2+b/2-1}}{2^{a/2+b/2}\Gamma(a/2+b/2)} \exp(-z/2) w^{a/2-1} (1-w)^{b/2-1} \frac{\Gamma(a/2+b/2)}{\Gamma(a/2)\Gamma(b/2)},$$

e, portanto, $W \sim \text{Beta}(a/2, b/2)$. Em particular, $W \perp Z$. Daí, concluímos que sob H_0 , $R^2 \sim \text{Beta}(P/2, (n - P - 1)/2)$. ■

Comentário: Nesta questão investigamos as propriedades do famoso coeficiente de determinação, R^2 . Mostramos sua forma matemática, interpretação e as condições sob as quais esse diagnóstico faz sentido. Mostramos ainda que ele não diminui ao se incluir mais variáveis, o que pode parecer uma característica interessante, mas na verdade esconde o fato de que o R^2 não penaliza a falta de parcimônia. A derivação das distribuições amostrais e da independência de S_0 e S_1 no item c) é um caso particular do Teorema de Cochran, aplicado às matrizes de projeção J , $H - J$ e $I - H - J$.

2. You have no leverage over me

Considere o modelo linear $y = X\beta + \varepsilon$, onde $y \in \mathbb{R}^n$, $X \in \mathbb{R}^{n \times p}$, $\beta \in \mathbb{R}^p$ e $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. Os resíduos do modelo são $e_i = y_i - x_i^\top \hat{\beta}$. A alavancagem de uma observação x_i é definida como $h_i = H_{ii} = x_i^\top (X^\top X)^{-1} x_i$, onde $H = X(X^\top X)^{-1} X^\top$ é a matriz chapéu.

É possível que algumas observações tenham muito mais influência nos valores dos parâmetros ajustados pelo modelo do que outras. Estas observações podem ser *outliers*, pontos que têm resíduos de grande magnitude, ou *pontos de alavanca*, onde h_i é alto.

Sejam $X_{(i)}$ a matriz de covariáveis sem a i -ésima linha e $y_{(i)}$ o vetor de variáveis dependentes sem a i -ésima entrada. Denotamos por $\hat{\beta}_{(i)} \in \mathbb{R}^p$ os parâmetros ajustados pelo modelo desconsiderando a i -ésima observação. Uma forma de medir a influência de uma observação (x_i, y_i) é usando a distância de Cook

$$D_i = \frac{\|\hat{y} - \hat{y}_{(i)}\|_2^2}{p\hat{\sigma}^2},$$

onde $\hat{y}_{(i)} = X\hat{\beta}_{(i)}$ e $\hat{\sigma}^2$ é o estimador da variância no modelo completo.

- (10 pontos) Interprete geometricamente o que é um ponto de alavanca em termos da posição de x_i em relação às demais linhas de X .
- (10 pontos) Mostre que $X_{(i)}^\top X_{(i)} = X^\top X - x_i x_i^\top$ e $X_{(i)}^\top y_{(i)} = X^\top y - x_i y_i$.
- (10 pontos) Use a fórmula de Sherman-Morrison para mostrar que

$$(X_{(i)}^\top X_{(i)})^{-1} = (X^\top X)^{-1} + \frac{(X^\top X)^{-1} x_i x_i^\top (X^\top X)^{-1}}{1 - h_i}.$$

$$\text{Conclua que } \hat{\beta} - \hat{\beta}_{(i)} = \frac{(X^\top X)^{-1} x_i e_i}{1 - h_i}.$$

Conceitos trabalhados: modelo linear multivariado; matriz chapéu; funções de influência; bondade do ajuste. **Nível de dificuldade:** médio.

Resolução: Para o primeiro item, vamos supor, por simplicidade que as colunas de X foram normalizadas de modo que têm média zero e matriz de covariância I_p . Nesse caso, $X^\top X = nI_p$ e portanto $h_{ii} = \frac{1}{n} x_i^\top x_i = \frac{1}{n} \|x_i\|_2^2$. Assim, um ponto com alavancagem alta é aquele cuja norma do vetor de covariáveis é grande em relação às demais observações. Geometricamente, isso significa que

x_i é um ponto de alavanca se está muito distante do centro de massa das observações. Para o segundo item, note que

$$\begin{aligned} X_{(i)}^\top X_{(i)} &= \sum_{j \neq i} x_j x_j^\top, \\ &= \sum_{j=1}^n x_j x_j^\top - x_i x_i^\top, \\ &= X^\top X - x_i x_i^\top. \end{aligned}$$

Do mesmo modo,

$$\begin{aligned} X_{(i)}^\top y_{(i)} &= \sum_{j \neq i} x_j y_j, \\ &= \sum_{j=1}^n x_j y_j - x_i y_i, \\ &= X^\top y - x_i y_i. \end{aligned}$$

Usando estes resultados,

$$\left(X_{(i)}^\top X_{(i)} \right)^{-1} = \left(X^\top X - x_i x_i^\top \right)^{-1}.$$

E, portanto, pela fórmula de Sherman-Morrison,

$$\left(X^\top X - x_i x_i^\top \right)^{-1} = \left(X^\top X \right)^{-1} + \frac{\left(X^\top X \right)^{-1} x_i x_i^\top \left(X^\top X \right)^{-1}}{1 - x_i^\top \left(X^\top X \right)^{-1} x_i}.$$

Por fim, observe que $\hat{\beta} = \left(X^\top X \right)^{-1} X^\top y$ e que

$$\begin{aligned} \hat{\beta}_{(i)} &= \left(X_{(i)}^\top X_{(i)} \right)^{-1} X_{(i)}^\top y_{(i)}, \\ &= \left(\left(X^\top X \right)^{-1} + \frac{\left(X^\top X \right)^{-1} x_i x_i^\top \left(X^\top X \right)^{-1}}{1 - x_i^\top \left(X^\top X \right)^{-1} x_i} \right) \left(X^\top y - x_i y_i \right), \\ &= \hat{\beta} - \left(X^\top X \right)^{-1} x_i y_i + \frac{\left(X^\top X \right)^{-1} x_i x_i^\top}{1 - h_i} \hat{\beta} - \frac{\left(X^\top X \right)^{-1} x_i h_i y_i}{1 - h_i}, \\ &= \hat{\beta} + \frac{\left(X^\top X \right)^{-1} x_i x_i^\top}{1 - h_i} \hat{\beta} - \frac{\left(X^\top X \right)^{-1} x_i y_i}{1 - h_i}, \\ &= \hat{\beta} - \frac{\left(X^\top X \right)^{-1} x_i e_i}{1 - h_i}. \end{aligned}$$

■

Comentário: Nesta questão vimos como a distância de Cook é deduzida. É interessante notar que no modelo linear é possível expressar a diferença entre o coeficiente estimado com e sem uma observação em forma fechada, sem a necessidade de reajustar o modelo.

3. What we do in the shadows

Uma analista acredita que suas observações são explicadas por um modelo linear da forma $y = X\beta + Z\gamma + \varepsilon$, onde $X \in \mathbb{R}^{n \times p}$ e $Z \in \mathbb{R}^{n \times q}$ são matrizes de covariáveis e $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$. Entretanto, as covariáveis Z não foram observadas. Então o analista decide ajustar um modelo linear apenas com as covariáveis X .

- a) (5 pontos) Encontre a distribuição dos erros no modelo ajustado. Como as hipóteses do modelo linear estão sendo violadas?
- b) (10 pontos) Seja $\hat{\beta}$ o estimador de mínimos quadrados ajustado usando o modelo incorreto. Mostre que

$$\hat{\beta} = \beta + (X^\top X)^{-1} X^\top Z \gamma + (X^\top X)^{-1} X^\top \varepsilon.$$

- c) (5 pontos) Calcule o viés do estimador $\hat{\beta}$. Mostre que o viés se anula se, e somente se, $X^\top Z = 0$. Interprete essa condição.
- d) (10 pontos) Compare $\text{Var}(\hat{\beta})$ com a variância do estimador de mínimos quadrados no modelo correto. A variância é afetada pela omissão de Z ?

Conceitos trabalhados: premissas; variável de confusão; viés e variância de estimadores lineares.

Nível de dificuldade: médio.

Resolução: No modelo ajustado, o erro corresponde a $u = Z\gamma + \varepsilon \sim \mathcal{N}(Z\gamma, \sigma^2 I_n)$. Isso viola a hipótese de exogeneidade se X e Z são correlacionados, ou seja, de que $\mathbb{E}[X^\top u] = 0$, já que $\mathbb{E}[X^\top u] = X^\top Z\gamma$. Além disso, $\mathbb{E}[u | X] = Z\gamma \neq 0$. Para encontrar o estimador, basta usar que $\hat{\beta} = (X^\top X)^{-1} X^\top y$. Substituindo a expressão de y ,

$$\hat{\beta} = \beta + (X^\top X)^{-1} X^\top Z \gamma + (X^\top X)^{-1} X^\top \varepsilon.$$

Consequentemente, seu viés é dado por

$$\mathbb{E}[\hat{\beta}] = \beta + (X^\top X)^{-1} X^\top Z \gamma,$$

e, portanto,

$$\begin{aligned} \mathbb{E}[\hat{\beta} - \beta] &= 0 \Leftrightarrow (X^\top X)^{-1} X^\top Z \gamma = 0, \\ &\Leftrightarrow X^\top Z \gamma = 0, \\ &\Leftrightarrow X^\top Z = 0, \\ &\Leftrightarrow x_i^\top Z_i = 0, \forall i = 1, \dots, n. \end{aligned}$$

ou seja, as linhas de X devem ser ortogonais às colunas de Z (não há correlação). Por fim,

$$\begin{aligned} \text{Var}(\hat{\beta}) &= \mathbb{E}[(\hat{\beta} - \mathbb{E}\hat{\beta})(\hat{\beta} - \mathbb{E}\hat{\beta})^\top], \\ &= \mathbb{E}[(X^\top X)^{-1} X^\top \varepsilon \varepsilon^\top X (X^\top X)^{-1}], \\ &= \sigma^2 (X^\top X)^{-1} X^\top X (X^\top X)^{-1}, \\ &= \sigma^2 (X^\top X)^{-1}. \end{aligned}$$

Sob o modelo correto, a variância do estimador de mínimos quadrados para (β, γ) é

$$\sigma^2 \left(\begin{bmatrix} X & Z \end{bmatrix}^\top \begin{bmatrix} X & Z \end{bmatrix} \right)^{-1} = \sigma^2 \begin{bmatrix} X^\top X & X^\top Z \\ Z^\top X & Z^\top Z \end{bmatrix}^{-1}.$$

A menos que esta matriz em blocos seja triangular (ou seja, $X^\top Z = 0$ ou $Z^\top X = 0$), o bloco correspondente a β na matriz de covariância conjunta será

diferente de $\sigma^2(X^\top X)^{-1}$. Portanto, a variância do estimador de mínimos quadrados para β também é diferente, e a igualdade vale apenas quando $X^\top Z = 0$. ■

Comentário: Nesta questão investigamos um fenômeno importante em modelos de regressão, que é o viés da variável omitida (*omitted variable bias*). Como vimos, omitir algumas variáveis causa viés em caso de colinearidade. Mais que isso, perde-se também eficiência. Note que não se trata de uma troca viés-variância: não incluir todas as variáveis resulta em um estimador viesado e ineficiente. Isso tem consequências para a interpretação dos coeficientes estimados, também.